



Università degli Studi di Salerno

Laurea Magistrale in Ingegneria Informatica
Dipartimento di Ingegneria dell'Informazione, Elettrica e Matematica
Applicata (DIEM)

Modello convoluzionale per la segmentazione di filamenti solari su immagini H-alpha

Project work di Machine Learning

Team

2026_MLrec_gr02

Componente

Francesco Peluso IE22700088

f.peluso29@studenti.unisa.it

Anno accademico 2025/2026

1 Introduzione

Questa relazione descrive come abbiamo progettato, addestrato e selezionato il modello che consegniamo per la segmentazione dei filamenti solari nelle immagini H-alpha, e anche quali ipotesi abbiamo provato e dovuto respingere lungo il percorso.

Due fatti hanno condizionato quasi tutte le nostre decisioni. Primo, **le annotazioni sono soggettive**: ogni osservazione è stata tracciata da un massimo di tre esperti che concordano tra loro solo fino a un Dice di 0,62, quindi parte dell'errore che misuriamo è disaccordo tra esperti e non errore del modello. Secondo, **sono in gioco due punteggi diversi**: la traccia del project work valuta il Mean Dice, mentre la challenge Kaggle ordina la sua leaderboard con la Panoptic Quality (PQ). La configurazione consegnata è ottimizzata per il primo; la seconda è studiata a parte, nella Sezione 7.3.

I contributi principali sono:

- una U-Net con encoder ResNet18 pre-addestrato che raggiunge **Dice 0,6815** in validazione, sopra l'accordo inter-annotatore, dentro il budget GPU opzionale (3,04 GB in training, 2,50 GB in inferenza);
- una pipeline di valutazione che reimplementa la PQ della challenge ed è verificata contro il codice degli organizzatori a 3×10^{-8} , così ogni numero di validazione è direttamente confrontabile con la leaderboard;
- uno stadio di post-processing i cui quattro iper-parametri sono cercati a griglia congiuntamente sul validation set – vale più della maggior parte delle modifiche all'addestramento e non costa un minuto di training;
- un registro di falsificazioni: quindici run di addestramento e una dozzina di meccanismi post-hoc misurati e, in gran parte, respinti, insieme a una soglia di rumore misurata sotto la quale un guadagno in validazione non è credibile.

La Sezione 2 richiama gli ingredienti e le metriche, la Sezione 3 i dati e il protocollo di valutazione, la Sezione 4 il modello e il suo addestramento, la Sezione 5 come sono stati pianificati gli esperimenti, la Sezione 6 cosa hanno prodotto, la Sezione 7 dove vive l'errore residuo, e la Sezione 8 conclude.

2 Background: predizione densa e metriche a istanze

2.1 Predizione densa

Una CNN di classificazione risponde a una domanda per immagine: i suoi stadi di pooling scartano progressivamente *dove* stanno le cose per decidere *cosa* è l'immagine. La segmentazione chiede l'opposto – una decisione per pixel – quindi il dettaglio spaziale buttato dall'encoder va ricostruito. Un decoder di convoluzioni trasposte può riportare il collo di bottiglia a piena risoluzione, ma per strutture larghe pochi pixel non basta: arrivato al collo di bottiglia, un filamento sottile è già stato eliminato dal pooling e nessun upsampling può reinventarlo. La **U-Net** [1] risolve esattamente questo con le skip connection che copiano ogni stadio dell'encoder nello stadio del decoder alla stessa risoluzione: il dettaglio fine viaggia *attorno* al collo di bottiglia invece che *attraverso*. Per filamenti scuri, sottili e allungati quelle skip non sono una rifinitura: sono il motivo per cui la predizione esiste.

L'encoder non deve essere addestrato da zero. Le reti residuali [2] pre-addestrate su ImageNet [3] forniscono filtri generali di bordi e texture, cosa che conta quando il training set è piccolo.

2.2 Metriche a istanze

Due maschere P e G si confrontano con l'Intersection over Union o con il coefficiente di Dice, strettamente imparentato,

$$\text{IoU}(P, G) = \frac{|P \cap G|}{|P \cup G|}, \quad \text{Dice}(P, G) = \frac{2|P \cap G|}{|P| + |G|}, \quad (1)$$

entrambe misure a livello di pixel. La **Panoptic Quality** [4] valuta invece oggetti: istanze predette e annotate vengono accoppiate quando la loro IoU supera 0,5, e

$$\text{PQ} = \underbrace{\frac{\sum_{\text{TP}} \text{IoU}}{|\text{TP}|}}_{\text{SQ}} \times \underbrace{\frac{|\text{TP}|}{|\text{TP}| + \frac{1}{2}|\text{FP}| + \frac{1}{2}|\text{FN}|}}_{\text{RQ}}, \quad (2)$$

qualità della segmentazione per qualità del riconoscimento. È la fattorizzazione a rendere la PQ diagnostica: SQ dice quanto bene si sovrappongono le maschere accoppiate, RQ quanti oggetti vengono trovati. Le due metriche divergono in modo informativo: una predizione frammentata o rumorosa muove appena il Dice e distrugge RQ.

3 Dati e protocollo di valutazione

3.1 Annotazioni e accordo tra annotatori

Il training set ha **707 osservazioni**. Le annotazioni sono COCO, con una proprietà strutturale che ha plasmato ogni decisione del progetto: ogni voce è *la vista di un singolo annotatore* su un'osservazione, e la stessa immagine compare fino a tre volte con poligoni diversi (1154 record in totale, 8199 filamenti annotati). Le maschere sono disegnate a mano da annotatori umani e quindi soggette a omissioni ed errori: non sono una ground truth perfetta. Gli annotatori sono genuinamente in disaccordo: sulle 296 osservazioni annotate da più di una persona, il Dice medio tra due annotatori della *stessa* immagine è 0,62.

Quel numero misura il rumore delle etichette, non il massimo ottenibile da un modello. Il punteggio confronta la predizione con *ogni* annotatore separatamente e poi media, quindi una predizione vicina al consenso paga solo i propri errori, mentre un annotatore usato come predittore paga anche le idiosincrasie del collega. Lo abbiamo misurato: la maschera di maggioranza degli annotatori – un oracolo, costruito dalle stesse annotazioni contro cui lo valutiamo – ottiene un Dice medio di **0,81** contro i singoli annotatori. Il tetto pratico sta lì, non a 0,62: il modello consegnato arriva a 0,68 (Sezione 6), sopra l'accordo tra due umani ma con ancora $\approx 0,13$ di margine, che la Sezione 7 attribuisce al riconoscimento dei filamenti piccoli e non alla precisione dei contorni.

I filamenti sono inoltre piccoli e rari (Figura 1): l'istanza mediana copre ≈ 1230 pixel e tutte insieme solo lo 0,4% dell'immagine, il che esclude una cross-entropy pura e rende la risoluzione d'ingresso una variabile di prim'ordine.




Figura 1: Tre osservazioni di training: immagine H-alpha (a sinistra) e maschera binaria di un annotatore (a destra), con il numero di filamenti e la frazione di pixel positivi.

3.2 Protocollo di split

Lo split è sui **nomi dei file, mai sui record di annotazione**: due annotatori di un'osservazione descrivono gli stessi pixel, e dividere per record farebbe trapelare pixel di validazione nel training gonfiando ogni punteggio. Il seed 22 divide le 707 osservazioni in tre blocchi da 494, 106 e 107, salvati in `splits/split_seed22.csv`. Il terzo era un test interno, mai consultato per scegliere alcunché; dal settimo esperimento in poi abbiamo abbandonato lo split triplo e lo abbiamo incorporato nel training, dove 107 osservazioni valgono di più. Il protocollo effettivo, quello del modello consegnato, è quindi a due vie: **601 osservazioni di training e 106 di validazione**, con il validation set come unico strumento di selezione di iper-parametri, checkpoint e operating point.

3.3 La metrica ufficiale, reimplementata

La traccia del project work adotta il **Mean Dice** come punteggio di valutazione; la challenge Kaggle valuta la sua leaderboard con la **Panoptic Quality**, quindi teniamo traccia di entrambe. La PQ della challenge differisce dalla definizione da manuale della Sezione 2 in tre punti che cambiano tutti l'aspetto di una buona predizione: la ground truth è un'istanza per annotazione e non le componenti connesse dell'unione dei poligoni di tutti gli annotatori; ogni annotatore è una voce di valutazione separata, quindi una stessa predizione viene valutata due o tre volte contro esperti in disaccordo tra loro; e TP, FP e FN si accumulano globalmente sull'intero split invece di essere mediati per immagine. La pipeline reimplementa esattamente quella definizione e la verifica contro il codice pubblicato dagli organizzatori, con un accordo di 3×10^{-8} .

4 Modello e addestramento

4.1 Architettura

Il modello è la U-Net della Sezione 2 con un **encoder ResNet18 pre-addestrato su ImageNet** (Figura 2): con meno di 500 osservazioni di training, imparare da zero bordi e texture spreca il budget di dati. La testa di classificazione viene scartata e i quattro blocchi convoluzionali alimentano il decoder U-Net attraverso le skip connection. Una riscrittura algebrica a tantum ripiega lo stem RGB e la normalizzazione ImageNet in una convoluzione a canale singolo esattamente equivalente, così le immagini in scala di grigi entrano direttamente a un terzo della banda d'ingresso. L'architettura resta poi fissa per tutto lo studio: una variabile per esperimento è ciò che rende significativi i confronti.

Tre alternative sono state considerate e scartate per ragioni dichiarate e verificabili. Le **architetture di instance segmentation** come Mask R-CNN [8] ricostruiscono ogni maschera da una griglia 28×28 dentro un box allineato agli assi – un sovracampionamento di $\sim 25\times$ per oggetti la cui proprietà distintiva è essere larghi pochi pixel e lunghi centinaia – e filamenti allungati e diagonali producono box sovrapposti e quasi tutti di sfondo, il regime peggiore per l'anchor matching. L'affermazione è stata poi verificata empiricamente invece di restare sulla carta: un detector YOLOv8x-seg [10] addestrato sullo stesso split raggiunge un punteggio a istanze competitivo (PQ 0,426) ma un Dice nettamente peggiore (0,632 contro 0,68), confermando la scelta per il punteggio della traccia. **Encoder più grandi e transformer**: in ogni capacità e risoluzione provata la qualità delle maschere accoppiate non si è mai mossa (Sezione 7), quindi la capacità non è il vincolo attivo, mentre il budget di dati sconsiglia modelli più affamati. Le **pipeline non neurali** (sogliatura più morfologia): il contrasto H-alpha varia fortemente tra osservazioni, e una regola fotometrica globale non può separare i filamenti da macchie solari e oscuramento al bordo.




Figura 2: A sinistra: l’encoder–decoder U-Net con le skip connection. A destra: l’encoder ResNet18 che sostituisce quello da zero; la testa di classificazione viene scartata e i quattro blocchi convoluzionali alimentano il decoder U-Net.

4.2 Loss, ottimizzazione e implementazione

La loss è una combinazione a pesi uguali di binary cross-entropy e soft Dice [5]: il Dice è immune al tasso di positivi dello 0,4% ma non dice nulla sulla confidenza, mentre la BCE mantiene le probabilità *calibrate*, ciò che rende ben condizionata la ricerca della soglia della Sezione 6.2 – l’esperimento 3 mostra cosa succede quando quella calibrazione si perde. L’augmentation usa le otto simmetrie del quadrato, che preservano l’etichetta perché i filamenti non hanno orientamento canonico, più jitter fotometrico per il contrasto H-alpha variabile. L’ottimizzazione è AdamW [9], batch size 2, al più 20 epoche, con early stopping sul Dice di validazione. Il checkpoint si sceglie sul **Dice**, non sulla PQ: la PQ dipende fortemente da soglia e post-processing, regolati dopo sullo stesso validation set, quindi selezionare i pesi con essa ottimizzerebbe due quantità accoppiate in un colpo solo.

Due scelte implementative rendono sostenibile lo studio. Immagini e maschere sono decodificate *una sola volta* in cache uint8 mappate in memoria – tutta la ground truth a 1024^2 occupa 150 MB invece di 1,2 GB – così un’epoca legge solo byte invece di decodificare JPEG e rasterizzare poligoni. L’addestramento gira in precisione mista con gradient checkpointing alle risoluzioni più alte, e il picco di memoria GPU è *misurato* allo step che davvero raggiunge il massimo, mai stimato dal numero di parametri.

Tabella 1: Costo misurato della pipeline consegnata. Addestramento e ricerca dell’operating point girano su GPU Colab; l’inferenza è stata eseguita anche su GPU di un portatile. Entrambi i notebook girano senza modifiche in Colab e Kaggle, come richiede la traccia.

Passo	Costo
Addestramento, un’epoca (601 finestre da 1536^2)	105 s
Addestramento completo (19 epoche, early stopping)	33 min
Ricerca dell’operating point (1437 combinazioni a 2048^2)	10 min
Inferenza sulle 180 immagini di test, con TTA D4	14 min
Picco di memoria GPU in training (soglia bonus 5 GB)	3,04 GB
Picco di memoria GPU in inferenza (soglia bonus 4 GB)	2,50 GB

5 Disegno sperimentale

Gli esperimenti non sono una cronologia. Prima di addestrare qualunque cosa, le osservazioni della Sezione 3 sono state trasformate in una lista ordinata di ipotesi, ognuna delle quali cambia esattamente una variabile ed è falsificabile da un singolo numero:

1. un encoder-decoder standard trova già i filamenti principali, e dà una baseline con cui vale la pena confrontarsi;
2. con meno di 500 osservazioni il vincolo attivo è l'encoder, quindi le feature ImageNet devono battere l'inizializzazione casuale;
3. il Dice è cieco alla frammentazione, quindi una loss che non lo è – Tversky più cIDice – deve alzare la PQ dove il Dice non può;
4. parte di ciò che resta è il *dominio* H-alpha, non la loss;
5. ciò che limita il punteggio è la *scala*: a 512×512 un filamento largo sei pixel nativi ne diventa uno e mezzo.

Le ipotesi 3 e 5 fanno previsioni opposte su dove viva l'errore residuo, e solo una sopravvive al contatto con i dati. Le ipotesi successive sono state derivate allo stesso modo, ciascuna dall'analisi dell'errore del run precedente.

Due regole hanno tenuto onesto lo studio. Un candidato viene confrontato con il migliore precedente solo *al proprio operating point*, ricercato da capo, perché una loss o una risoluzione diversa spostano la calibrazione e riutilizzare una vecchia soglia falsificherebbe una buona idea per il motivo sbagliato. E un guadagno si crede solo se sopravvive alla **cross-selection**: l'operating point viene scelto su metà dei file di validazione e valutato sull'altra metà. Misurato così, su 169 voci di annotazione, **ogni guadagno sotto $\approx 0,005$ è indistinguibile dal rumore di selezione** – una soglia che ha poi ucciso tre meccanismi i cui numeri aggregati sembravano positivi.

Prima di iniziare abbiamo anche scritto cosa avremmo esplorato e quanto sarebbe costato, in modo che lo studio entrasse nel tempo a disposizione (Tabella 2).

Tabella 2: Il piano: cosa abbiamo deciso di esplorare e il costo di un run.

Cosa esploriamo	Valori considerati	Costo
risoluzione d'ingresso	512, 1024, 1536, 2048 nativo	10–35 min / run
encoder	U-Net da zero, ResNet18, ResNet34	10–35 min / run
loss	BCE+Dice, +Tversky, +cIDice, Dice per istanza, <code>pos_weight</code>	15–30 min / run
augmentation	simmetrie D4, jitter fotometrico, scale jitter	incluso sopra
paradigma	U-Net per pixel vs. detector YOLOv8	30 min – 2,5 h / run
post-processing	soglia, chiusura, dim. minima, gate	10 min, senza training

6 Risultati sperimentali

6.1 Esperimenti principali

Sono stati eseguiti quindici run; i sei che hanno cambiato la rotta del progetto sono nella Tabella 3.

Baseline e transfer (1–2). La U-Net da zero arriva a Dice 0,6415 all'ultima epoca, ancora in underfitting, con la soglia migliore al bordo della griglia di ricerca: probabilità mal calibrate che puntano all'encoder. L'encoder pre-addestrato aggiunge un punto di Dice e, cosa più utile, appiattisce la curva soglia-Dice: per una configurazione di inferenza da congelare prima di vedere il test set, la calibrazione vale più del punto.

Il fallimento istruttivo (3). Sostituire metà della loss con Tversky orientata al recall [6] più cIDice [7] fa crollare la validazione a Dice 0,49 e PQ 0,06 mentre la training loss scende:

Tabella 3: Gli esperimenti principali. Dice e PQ all’operating point di ciascun run, metrica ufficiale a 2048² nativo; i primi tre precedono quel protocollo e sono riportati a soglia 0,5 (contrassegnati *).

Esp.	Una variabile	Dice	PQ	Esito
1	U-Net da zero, 512 ²	0,6415*	–	baseline
2	encoder ResNet18 ImageNet	0,6552*	0,2505*	calibrazione, +1 pt Dice
3	loss topologica (Tversky + clDice)	0,4937*	0,0618*	falsificato , istruttivo
5	risoluzione 512 → 1024	0,6665	0,4022	il guadagno singolo maggiore
8	→ 1536, TTA D4, gate di confidenza	0,6729	0,4264	miglior PQ (singolo)
13	2048 nativo, finestre casuali 1536	0,6815	0,3930	miglior Dice – consegnato

il modello ottimizza con successo la cosa sbagliata. L’autopsia conta più del numero: a 512² molti filamenti sono larghi uno o due pixel, quindi lo scheletro soft che clDice richiede è rumore proprio sulle strutture che doveva proteggere. Un problema di *scala* travestito da problema di loss, e la ragione per cui esiste l’esperimento 5.

Risoluzione (5, 8). Non cambia nulla tranne la dimensione dell’input, 512 → 1024: il Dice guadagna un punto mentre la PQ salta del +28% relativo. L’asimmetria è la scoperta: la risoluzione cambia poco quanta parte del disco è coperta correttamente, e moltissimo quanti filamenti esistono come oggetti riconoscibili. Proseguendo a 1536 con la media sulle otto simmetrie del quadrato e un gate di confidenza si ottiene il miglior punteggio a istanze dello studio.

Pixel nativi (13). Addestrare su finestre casuali 1536² del frame 2048² intatto rimuove l’ultimo ridimensionamento dalla pipeline. *Perde* sul riconoscimento – le finestre rinunciano al contesto dell’intero disco – e *vince* sulla qualità delle maschere: Dice **0,6815**, il massimo dello studio, con training a 3,04 GB e inferenza a 2,50 GB, l’unica configurazione dentro il bonus memoria su entrambi i fronti (Figura 3).

Misurati e respinti. Altri nove run a variabile singola e una dozzina di meccanismi post-hoc sono stati falsificati, ognuno col suo numero: scale jitter (−0,019 PQ), una cascata detect-then-refine (−0,025), target di consenso soft (−0,033), clDice ritestata a 1536 dove la sua premessa era finalmente valida (−0,013), il Dice bilanciato per istanza come termine dominante (il controllo dei falsi positivi è collassato), un peso sulla classe positiva nella BCE (ha curato la sotto-segmentazione misurata pagandola in allucinazioni), soglie e dilatazioni per componente, e tre varianti di ricucitura post-hoc dei filamenti i cui guadagni aggregati sono morti in cross-selection.




Figura 3: Il modello consegnato (esperimento 13) in addestramento: loss e metriche a soglia 0,5. L’operating point viene scelto dopo.

6.2 Post-processing e operating point

La rete emette una probabilità per pixel. Trasformare quella mappa nelle istanze finali richiede quattro *iper-parametri di post-processing* – insieme formano l’*operating point*, selezionato con

una ricerca a griglia congiunta sul validation set (mai sul test set) perché i quattro interagiscono:

- **soglia** (0,50 nella configurazione consegnata): un pixel con probabilità superiore diventa filamento, sotto diventa background;
- **chiusura morfologica** (1 iterazione): riempie le discontinuità di un pixel, così un filamento spezzato in due dalla rete torna una componente sola – due falsi positivi e un falso negativo diventano un unico vero positivo;
- **dimensione minima di componente** (384 pixel a 2048^2): una componente connessa più piccola viene scartata per intero, perché ogni piccolo blob spurio costa un falso positivo pieno in PQ aggiungendo quasi nulla al Dice;
- **gate di confidenza** (0,90): una componente sopravvive solo se almeno un suo pixel supera questa probabilità. La soglia da sola svolge due ruoli insieme – decidere *quali* componenti esistono e la loro *estensione* – quindi alzarla per eliminare i blob deboli assottiglia anche ogni filamento vero; il gate si prende la decisione di esistenza e lascia le forme esattamente come le ha disegnate la soglia.

Tutto viene valutato a 2048^2 nativo, perché è lì che si scrive la submission: una dimensione minima regolata alla risoluzione di addestramento significa altro a scala nativa, e il numero di componenti connesse non è preservato dal ridimensionamento di una maschera. Misurato quando questo protocollo fu introdotto, selezionare a risoluzione nativa contro la definizione ufficiale valse +0,020 Dice e +0,006 PQ rispetto alla configurazione che sarebbe altrimenti partita – gratis, senza riaddestrare.

La stessa griglia di ricerca produce un punto per obiettivo. La **configurazione consegnata** è congelata sul Dice, il punteggio della traccia: soglia 0,50, chiusura 1, dimensione minima 384, gate 0,90, per **Dice 0,6815** (PQ 0,393) in validazione. La cross-selection quantifica il costo della griglia più fine in 0,0024, con entrambe le metà del validation set che selezionano la stessa soglia e lo stesso gate. Il punto PQ-ottimale dello stesso modello (0,407) e dello studio (0,4264, esperimento 8) restano registrati negli artefatti.




Figura 4: Dice e PQ di validazione al variare della soglia per il modello consegnato, senza post-processing: le due metriche hanno massimi diversi.

7 Analisi dell'errore e discussione

7.1 Qualità delle maschere e riconoscimento

In tredici esperimenti – ogni capacità, risoluzione e architettura provata – la qualità delle maschere accoppiate (SQ) si è mossa dentro 0,66–0,68 e non oltre, contro un accordo tra coppie di annotatori umani di 0,59; anche il Dice ha superato l'accordo tra due annotatori (0,62) già al secondo esperimento e da lì si è mosso poco. Questo non chiude il problema dei contorni: l'oracolo di consenso della Sezione 3 vale 0,81, quindi il margine esiste. Dice però che **nessuna delle variabili che abbiamo mosso lo tocca**: capacità, risoluzione e loss cambiano *quali* filamenti troviamo, non quanto bene li disegniamo. Ogni punto di PQ rimanente passa dal riconoscimento: trovare più filamenti tra quelli marcati dagli annotatori, predirne meno tra quelli non marcati.

7.2 Falsi negativi e falsi positivi

La Tabella 4 ordina per causa tutti gli errori del modello consegnato. Il recall per istanza crolla con la dimensione, da 0,31 sotto i 500 pixel a 0,73 sopra i 5000: quello che manchiamo sono filamenti piccoli e deboli. Split e merge insieme valgono solo il 5,4% di tutti gli errori, ed è per questo che non abbiamo mai costruito nessun meccanismo di split/merge: il premio era troppo piccolo per giustificare il codice.

Tabella 4: Tutti gli errori del modello consegnato in validazione, per causa.

	Causa	Conteggio	Cosa significa
FN (442)	pure miss	193	nemmeno un pixel predetto sull'istanza
	near miss	215	il blob c'è, ma la IoU resta $\leq 0,5$
	split	34	il filamento è trovato, ma a pezzi
FP (523)	allucinazione	209	nessun pixel annotato toccato
	non accoppiato	296	su un filamento annotato, ma sotto IoU 0,5
	merge	18	una predizione che copre due annotazioni

Due avvertenze sono state verificate. Primo, gli organizzatori hanno confermato che le annotazioni sono *incomplete*, quindi parte delle allucinazioni sono plausibilmente filamenti veri che uno o più annotatori hanno mancato – misurato, i blob con picco di probabilità sopra 0,85 sono marcati solo dal 63% degli annotatori, e diversi blob della mappa di probabilità in Figura 5 poggiano su strutture che nessun annotatore ha disegnato. Secondo, la struttura degli accoppiamenti che la giuria della challenge ispeziona è quasi uno-a-uno (Figura 6): su 1144 istanze annotate 951 sono toccate da almeno una predizione e solo 81 da più di una.

7.3 Massimizzare la PQ per la leaderboard Kaggle

Messo deliberatamente da parte il bonus memoria, il problema del riconoscimento è stato spinto fin dove poteva andare, e la leaderboard pubblica ha inseguito la PQ di validazione meno un divario stabile di $0,072 \pm 0,007$ su otto submission: la validazione è stata una bussola affidabile per tutto lo studio. I modelli a 2048 nativo a frame intero (encoder ResNet18 e ResNet34) eguagliano il campione; la media delle mappe di probabilità dei due modelli *quasi pari*, a *bias opposto e a scala diversa* li batte entrambi in cross-selection (PQ 0,4354), dove ogni altro tentativo di ensemble era fallito; e appendere le rilevazioni sicure di un detector YOLOv8x dove l'ensemble ha lasciato pixel liberi aggiunge i filamenti che i modelli per pixel mancano del tutto (PQ **0,4414**, cross-validata, leaderboard pubblica **0,37**). Queste configurazioni usano fino a 9–39 GB in training e sono documentate qui come studio sulla metrica della challenge Kaggle; il modello che consegniamo per il project work resta l'ottimo Dice dentro il budget della Sezione 6.2.

8 Conclusioni e sviluppi futuri

Il modello consegnato è l'esperimento 13 – una ResNet18-U-Net addestrata su finestre casuali 1536^2 del frame nativo 2048^2 – con la configurazione di inferenza, selezionata sul validation set, congelata sul punteggio della traccia: **Dice 0,6815** in validazione, il massimo dello studio, PQ 0,393 nello stesso punto, training a **3,04 GB** e inferenza a **2,50 GB**, dentro il budget GPU opzionale su entrambi i fronti. I notebook di training e test consegnati riproducono configurazione e submission da cima a fondo.

Tre lezioni valgono oltre questo dataset. **Misurare ciò che il punteggio misura, dove lo misura**: selezionare l'operating point a risoluzione nativa, contro la definizione ufficiale della




Figura 5: Il modello consegnato su tre osservazioni di validazione: ground truth dell’annotatore (a sinistra), mappa di probabilità predetta (al centro), istanze finali all’operating point consegnato (a destra). Diversi blob nelle mappe di probabilità poggiano su strutture che nessun annotatore ha disegnato.

metrica e sull’obiettivo effettivamente valutato, è valso più della maggior parte delle modifiche all’addestramento – tutto gratis. **Scegliere la metrica che vede il modo di fallire:** il Dice ha superato l’accordo tra due annotatori al secondo esperimento ed è poi rimasto quasi piatto; ogni miglioramento reale successivo era visibile solo nel termine di riconoscimento della PQ, e una valutazione limitata a una sola metrica avrebbe dichiarato il progetto concluso dieci esperimenti prima. **Un’ipotesi falsificata non è un run sprecato:** oltre venti idee sono state misurate e respinte, e ogni rigetto ha ridiretto lo sforzo – il fallimento dell’esperimento 3 ha esposto il problema della risoluzione, il fallimento di ogni meccanismo post-hoc ha mostrato che l’errore residuo vive nel supporto di probabilità del modello, e il protocollo di cross-selection ha separato i guadagni veri dal rumore di selezione al livello di $\pm 0,005$.

Il divario di riconoscimento che resta – il recall dei filamenti piccoli e deboli contro annotazioni incomplete – è, sull’evidenza raccolta qui, un problema di dati di addestramento più che di architettura. Due direzioni seguono direttamente: un protocollo cross-validato in cui ogni osservazione addestra un modello, così che l’operating point venga selezionato su $6,7\times$ più voci di annotazione e i guadagni sotto l’attuale soglia di rumore diventino misurabili; e il pseudo-




Figura 6: Le distribuzioni riportate dal notebook di autovalutazione degli organizzatori, per il modello consegnato sulla validazione: IoU e Dice su ogni coppia ground-truth/predizione sovrapposta, e le relazioni many-to-one / one-to-many (un hit è un qualunque overlap; il vincolo IoU $> 0,5$ della metrica è più severo).

labelling dei filamenti che il modello trova e nessun annotatore ha marcato, che gli organizzatori hanno confermato esistere nei dati.

Riferimenti bibliografici

- [1] O. Ronneberger, P. Fischer, T. Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI, 2015.
- [2] K. He, X. Zhang, S. Ren, J. Sun. *Deep Residual Learning for Image Recognition*. CVPR, 2016.
- [3] J. Deng et al. *ImageNet: A Large-Scale Hierarchical Image Database*. CVPR, 2009.
- [4] A. Kirillov, K. He, R. Girshick, C. Rother, P. Dollár. *Panoptic Segmentation*. CVPR, 2019.
- [5] F. Milletari, N. Navab, S.-A. Ahmadi. *V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation*. 3DV, 2016.
- [6] S. S. M. Salehi, D. Erdogmus, A. Gholipour. *Tversky Loss Function for Image Segmentation Using 3D Fully Convolutional Deep Networks*. MLMI, 2017.
- [7] S. Shit et al. *clDice: A Novel Topology-Preserving Loss Function for Tubular Structure Segmentation*. CVPR, 2021.
- [8] K. He, G. Gkioxari, P. Dollár, R. Girshick. *Mask R-CNN*. ICCV, 2017.
- [9] I. Loshchilov, F. Hutter. *Decoupled Weight Decay Regularization*. ICLR, 2019.
- [10] G. Jocher, A. Chaurasia, J. Qiu. *Ultralytics YOLOv8*. 2023. <https://github.com/ultralytics/ultralytics>
- [11] *Filament Segmentation Challenge 2026*, con il catalogo di annotazioni MAGFiLO v1.0. Kaggle, 2026. <https://www.kaggle.com/competitions/filament-segmentation-2026>