

Università degli Studi di Salerno

Laurea Magistrale in Ingegneria Informatica, DIEM

Segmentazione di filamenti solari

Project work di Machine Learning

Team

2026_MLrec_gr02

Componente

Francesco Peluso IE22700088

`f.peluso29@studenti.unisa.it`

Anno accademico 2025/2026

1 Il problema, i dati e le metriche

I filamenti solari sono nastri di plasma più freddo sospesi sul disco solare, visibili come strutture scure e allungate nelle immagini H-alpha. Il compito è una segmentazione binaria con una piega a istanze: data un'osservazione 2048×2048 , predire quali pixel appartengono a un filamento, separare la maschera in una componente connessa per filamento e inviare ogni componente come run-length encoding in formato COCO.

1.1 Com'è fatto il dataset

Il training set contiene **707 osservazioni** provenienti dalle sei stazioni della rete GONG (Big Bear, Cerro Tololo, Learmonth, Mauna Loa, El Teide, Udaipur), acquisite tra il 2011 e il 2022 con una forte prevalenza del massimo solare 2011–2015. Le annotazioni vengono dal catalogo MAGFiLO e hanno una struttura che ha plasmato l'intero progetto: ciascuno dei **1154 record di annotazione** è *la vista di un singolo annotatore* su un'osservazione. 411 file sono annotati da un solo esperto, 145 da due e 151 da tre, e gli annotatori sono genuinamente in disaccordo – il Dice medio tra due annotatori della *stessa* immagine è 0,62 (mediana 0,65).

Gli 8199 filamenti annotati sono piccoli e sottili: il filamento mediano copre circa 1230 pixel a risoluzione nativa (intervallo interquartile 670–2430, il 15% sotto i 500), e tutti i filamenti insieme coprono solo lo 0,4% circa dei pixel. Tre conseguenze guidano il progetto. Lo sbilanciamento estremo delle classi esclude una cross-entropy pura; strutture larghe pochi pixel vengono distrutte da un ridimensionamento aggressivo, il che renderà la *risoluzione* la variabile più produttiva dello studio; e con sole 494 osservazioni di training (il training set non è estendibile per regolamento), transfer learning e augmentation restano le uniche leve.

1.2 Metriche: IoU, Dice e Panoptic Quality

Due maschere P (predizione) e G (ground truth) si confrontano con l'**Intersection over Union** o con il coefficiente di **Dice**, strettamente imparentato:

$$\text{IoU}(P, G) = \frac{|P \cap G|}{|P \cup G|}, \quad \text{Dice}(P, G) = \frac{2|P \cap G|}{|P| + |G|}. \quad (1)$$

Entrambe sono misure a livello di pixel. Il Dice è ciò che il corso valuta; la submission Kaggle, però, chiede una riga per *filamento*, e la leaderboard riflette la **Panoptic Quality**. Istanze predette e annotate vengono accoppiate quando la loro IoU supera 0,5 (le coppie sono veri positivi, le predizioni spaiate falsi positivi, le annotazioni spaiate falsi negativi), e

$$\text{PQ} = \frac{\sum_{(p,g) \in \text{TP}} \text{IoU}(p, g)}{|\text{TP}| + \frac{1}{2}|\text{FP}| + \frac{1}{2}|\text{FN}|} = \underbrace{\frac{\sum \text{IoU}}{|\text{TP}|}}_{\text{SQ}} \times \underbrace{\frac{|\text{TP}|}{|\text{TP}| + \frac{1}{2}|\text{FP}| + \frac{1}{2}|\text{FN}|}}_{\text{RQ}}. \quad (2)$$

La fattorizzazione conta: la *Segmentation Quality* misura quanto bene si sovrappongono le istanze accoppiate, la *Recognition Quality* quante istanze vengono trovate. Il divario tra Dice e PQ è l'intera storia di questo progetto – un filamento spezzato in tre frammenti, o una maschera corretta circondata da venti macchioline di dieci pixel, sposta il Dice di una frazione di punto e fa crollare RQ.

La PQ della competizione, pubblicata nel notebook di autovalutazione degli organizzatori, differisce dalla definizione da manuale in tre punti che cambiano tutti l'aspetto di una buona predizione: la ground truth è *un'istanza per annotazione*, non le componenti connesse dell'unione dei poligoni di tutti gli annotatori; *ogni annotatore è una voce di valutazione separata*, quindi una stessa predizione viene valutata due o tre volte contro esperti in disaccordo tra loro;




Figura 1: A sinistra: l’encoder–decoder U-Net con le skip connection. A destra: l’encoder ResNet18 che sostituisce quello da zero dall’Esperimento 2 in poi; la testa di classificazione (a destra nella figura) viene scartata e i quattro blocchi convoluzionali alimentano il decoder U-Net attraverso le skip connection.

e TP/FP/FN si accumulano *globalmente* sull’intero split anziché per immagine. La pipeline reimplementa esattamente questa definizione e la verifica contro il codice di riferimento (accordo a 3×10^{-8}), quindi ogni numero di validazione di questa relazione è direttamente confrontabile con la leaderboard.

1.3 Quanto in alto si può arrivare

Il Dice inter-annotatore di 0,62 è un tetto pratico: oltre, un modello non sta segmentando meglio, sta imparando l’idea di un singolo esperto su dove finisce un filamento. Il numero riformula il problema – già dal secondo esperimento il modello è a quel tetto sul Dice mentre la PQ è intorno a 0,25, quindi il margine sta tutto in come la maschera è *organizzata in istanze*. Ogni ipotesi che segue nasce da questa osservazione.

2 Modello e pipeline

2.1 Una U-Net con encoder ResNet18 pre-addestrato

Una CNN di classificazione comprime l’immagine in un’unica predizione; la segmentazione ne richiede una per pixel, quindi il dettaglio spaziale che l’encoder scarta va reintrodotta. La U-Net lo fa con un encoder–decoder simmetrico e con le **skip connection** che copiano ogni stadio dell’encoder nello stadio del decoder alla stessa risoluzione (Figura 1, a sinistra). Per strutture sottili, allungate e irregolari le skip non sono una rifinitura: sono ciò che impedisce a un filamento di dissolversi nel collo di bottiglia. La rete emette un logit per pixel; una sigmoide lo trasforma in probabilità e una soglia scelta in validazione nella maschera binaria.

La baseline (Esperimento 1) usa un encoder addestrato da zero con 1,9M di parametri. Dall’Esperimento 2 in poi l’encoder è una **ResNet18 pre-addestrata su ImageNet** (Figura 1, a destra, senza la testa di classificazione), raffinata end-to-end: con meno di 500 osservazioni di training, imparare da zero bordi e texture spreca il budget di dati. Il decoder resta lo stesso, quindi il confronto isola l’encoder. L’architettura viene poi tenuta fissa per il resto dello studio, di proposito: una variabile per esperimento è ciò che dà senso ai confronti.

Un’ottimizzazione gratuita merita un paragrafo. Dare un’immagine in scala di grigi a un encoder ImageNet di solito significa replicare il canale tre volte e normalizzare con media m_c e deviazione standard s_c RGB. Scrivendo la pre-attivazione dello stem per un’immagine g la ridondanza è evidente:

$$\sum_c W_c * \frac{g - m_c}{s_c} = \left(\sum_c \frac{W_c}{s_c} \right) * g - k, \quad (3)$$

dove k è una costante per canale d'uscita che la batch norm immediatamente successiva assorbe nella propria media. Lo stem a tre canali viene quindi sostituito da uno *a canale singolo* esattamente equivalente: i pesi pre-addestrati sono interamente preservati, il tensore d'ingresso si riduce di tre volte e la normalizzazione sparisce dalla pipeline dei dati.

2.2 Loss e protocollo di addestramento

La loss è una miscela in parti uguali di binary cross-entropy e soft Dice. Ogni termine fa un lavoro che l'altro non può fare: il Dice è immune al tasso di positivi dello 0,4% ma non dice nulla sulla confidenza, mentre la BCE mantiene le probabilità *calibrate*, che è ciò che rende ben condizionata la ricerca della soglia della Sezione 4. L'Esperimento 3 mostra cosa succede quando quella calibrazione si perde.

Il protocollo è identico in ogni run. Lo split è sui **nomi dei file**, mai sui record di annotazione – lo stesso JPEG compare fino a tre volte nel file COCO, una per annotatore, e dividere per record metterebbe una copia in training e una in validazione, gonfiando ogni punteggio. Il seed 22 dà 494/106/107 osservazioni (806/169/179 record), salvate in `splits/split_seed22.csv`; il test interno si consulta una volta sola, a tutto congelato. L'augmentation usa le otto simmetrie del quadrato (i filamenti non hanno orientamento canonico) più jitter fotometrico. L'ottimizzazione è AdamW, batch size 2, al più 20 epoche, early stopping sul Dice di validazione con pazienza 8. Il checkpoint si sceglie sul **Dice**, non sulla PQ: la PQ dipende fortemente da soglia e post-processing, regolati dopo sullo stesso insieme di validazione, e scegliere i pesi con essa ottimizzerebbe due quantità accoppiate in un colpo solo.

2.3 Ingegneria: velocità di iterazione e memoria

Decodificare un JPEG 2048² e rasterizzarne i poligoni costa più di un forward e un backward; fatto dentro il dataset, quel prezzo si ripaga a ogni epoca. Tutte le immagini e le maschere vengono quindi decodificate *una sola volta* in array uint8 mappati in memoria (maschere impacchettate a bit: tutta la ground truth a 1024² occupa 150 MB invece di 1,2 GB), e ogni run riusa la cache. L'addestramento gira in precisione mista con gradient checkpointing alle risoluzioni più alte; il picco di memoria GPU è misurato nel momento in cui uno step raggiunge davvero il massimo, non stimato dai parametri. Rispetto al budget opzionale della consegna (5 GB in training, 4 GB in test), l'inferenza resta ampiamente dentro a 2,5 GB; il training ha misurato 3,7 GB a 1024² e 5,2 GB per la ricetta full-frame 1536² del modello finale – una configurazione a finestre native (Esperimento 13, Sezione 5) riporta lo stesso step a 3,0 GB, ma ha perso PQ e non è stata mantenuta. Le mappe di probabilità di validazione sono salvate in uint8 – la griglia delle soglie ha passi molto più grossi di 1/255 – ed è questo che rende sostenibile a risoluzione nativa la ricerca congiunta dell'operating point della Sezione 4.

3 Prima campagna: esperimenti 1–5

Gli esperimenti non sono una cronologia. Prima di addestrare qualunque cosa, le osservazioni della Sezione 1 sono state trasformate in una lista ordinata di ipotesi, ognuna delle quali cambia esattamente una cosa ed è falsificabile da un singolo numero: (1) un encoder-decoder standard trova già i filamenti principali; (2) con meno di 500 osservazioni il collo di bottiglia è l'encoder, quindi le feature ImageNet devono battere l'inizializzazione casuale; (3) il Dice è cieco alla frammentazione, quindi una loss consapevole della topologia deve alzare la PQ; (4) parte del residuo è il *dominio* H-alpha, non la loss; (5) ciò che limita la PQ è la *scala*. Le ipotesi 3 e 5 fanno previsioni opposte su dove vive l'errore, e solo una sopravvive al contatto coi dati.

Esperimenti 1–2, baseline e transfer learning. La U-Net da zero arriva a Dice 0,6415 all'ultima epoca, ancora in underfitting, con la soglia migliore al bordo della griglia – segno

di probabilità mal calibrate che punta all’encoder. Sostituirlo con la ResNet18 pre-addestrata porta il Dice a 0,6552 all’epoca 8 e, cosa più utile, appiattisce la curva soglia–Dice: per una submission la cui soglia va congelata alla cieca, quella calibrazione vale più del punto di Dice.

Analisi dell’errore. A 0,655 il Dice è già a livello inter-annotatore, eppure la PQ è 0,2505. Scomponendo: SQ = 0,61 (le istanze accoppiate si sovrappongono bene) ma RQ = 0,38. I falsi positivi sono uno sciame di componenti spurie minuscole (mediana 7 pixel), non frammentazione – il 74% dei filamenti sopra i 32 pixel è predetto come componente unica. Questa diagnosi è ciò che rende l’Esperimento 3 degno di essere eseguito, ed è ciò che il post-processing sfrutterà.

Esperimento 3, loss topologica – falsificato. Sostituire metà della loss con Tversky ($\beta = 0,7$) più clDice (un Dice tra scheletri soft) fa crollare il Dice di validazione a 0,4937 e la PQ a 0,0618, mentre la training loss scende: il modello ottimizza con successo la cosa sbagliata. Due lezioni. Il bias verso il recall di Tversky ingrossa tutto e distrugge la calibrazione appena comprata dal transfer learning; e a 512^2 molti filamenti sono larghi uno o due pixel, quindi lo scheletro soft è rumore proprio sulle strutture che clDice doveva proteggere – un problema di scala travestito da problema di loss, e il primo indizio che l’ipotesi 5 punta alla variabile giusta.

Esperimento 4, il dominio H-alpha. Normalizzazione ImageNet (ripiegata nello stem), jitter fotometrico e cosine annealing: Dice 0,6591, PQ 0,2656, e la curva di validazione ora migliora fino all’ultima epoca invece di fermarsi all’ottava.

Esperimento 5, risoluzione – il singolo guadagno più grande. Non cambia nulla tranne la dimensione dell’input, $512 \rightarrow 1024$. Il Dice guadagna un punto (0,6701) mentre la PQ salta da 0,2656 a 0,3397, +28% relativo (Figura 2). L’asimmetria è il punto: raddoppiare la risoluzione cambia poco quanta parte del disco è coperta correttamente, e cambia moltissimo quanti filamenti esistono come oggetti riconoscibili. Quello che sembrava un problema di loss era un problema di campionamento.

Tabella 1: Prima campagna. Dice e PQ a soglia 0,5 senza post-processing, così le colonne sono direttamente confrontabili; l’operating point viene scelto dopo (Sezione 4).

Esp.	Ipotesi in verifica	Dice	PQ	Epoca migliore
1	U-Net da zero (baseline)	0,6415	–	20
2	Encoder ResNet18 ImageNet	0,6552	0,2505	8
3	Loss Tversky + clDice	0,4937	0,0618	13
4	Aug. fotometrica + normalizz. + cosine	0,6591	0,2656	18
5	Risoluzione $512 \rightarrow 1024$	0,6701	0,3397	15
<i>accordo inter-annotatore</i>		<i>0,62</i>	–	




Figura 2: Esperimento 5 a 1024×1024 . La PQ di validazione, la curva più bassa a destra, guadagna dal cambio di scala molto più del Dice.

4 Dalle probabilità alla submission

L’addestramento produce una mappa di probabilità; quattro decisioni la trasformano nella maschera che viene valutata, e insieme valgono più PQ di qualunque singola modifica all’addestramento. Tutte si scelgono solo in validazione, e *congiuntamente*, perché interagiscono – regolare prima la soglia e poi i filtri blocca su un punto peggiore (sull’Esperimento 5, 0,389 in sequenza contro 0,401 congiunto).

- la **soglia** che binarizza la mappa di probabilità;
- la **chiusura morfologica**, che ricongiunge un filamento spezzato in due dalla rete, convertendo due FP e un FN in un TP;
- una **dimensione minima di componente**, che elimina le componenti spurie minuscole della Sezione 3, ognuna delle quali costa un falso positivo intero;
- un **gate di confidenza**: una componente sopravvive solo se la sua probabilità supera il gate da qualche parte. La soglia da sola fa due mestieri insieme – decidere *quali* blob esistono e *quanto sono spessi* – quindi alzarla per uccidere i blob deboli assottiglia anche ogni filamento vero. Il gate si prende la decisione di esistenza e lascia i contorni dove li ha disegnati la soglia.

La test-time augmentation sulle otto simmetrie del quadrato media otto mappe di probabilità e resta dietro un flag; la soglia va poi ri-selezionata sulle mappe mediate, altrimenti la TTA sembra dannosa quando non lo è.

4.1 Misurare ciò che misura la leaderboard, dove lo misura

Perché un numero di validazione significhi qualcosa, due cose devono essere giuste. **Cosa**: la PQ ufficiale della Sezione 1.2, reimplementata e verificata a 3×10^{-8} contro il codice degli organizzatori. Sull’unione di due o tre annotatori un’immagine porta circa undici filamenti contro meno di sette per ciascun singolo annotatore, quindi un modello regolato sulla definizione sbagliata sovra-predice sistematicamente. **Dove**: la submission si scrive a 2048², ma i primi operating point erano scelti alla risoluzione di addestramento – un disallineamento di protocollo, visto che una dimensione minima regolata a 1024 significa altro a 2048 e il numero di componenti connesse non è affatto preservato dal ridimensionamento di una maschera. Il rimedio è ingrandire la mappa di *probabilità* a risoluzione nativa e solo lì sogliare, post-processare e valutare. Misurato sull’Esperimento 5, selezionare a risoluzione nativa contro la metrica ufficiale vale +0,020 Dice e +0,006 PQ rispetto alla ricetta che sarebbe altrimenti partita (Tabella 2) – gratis, senza riaddestrare.

Tabella 2: Esperimento 5, stesso checkpoint, quattro modi di scegliere l’operating point, tutti valutati con la metrica ufficiale a 2048².

Protocollo di selezione	t	chiusura / dim. min.	Dice	PQ	SQ	RQ
a 1024 su PQ	0,65	1 / 512	0,6462	0,3901	0,660	0,591
a 1024 su Dice+PQ	0,90	1 / 256	0,6590	0,3964	0,662	0,599
a 2048, metrica interna	0,70	2 / 256	0,6653	0,3965	0,660	0,601
a 2048, metrica ufficiale	0,75	2 / 256	0,6665	0,4022	0,662	0,608

Un’ultima rifinitura è arrivata tardi e non è costata nulla: la leaderboard riporta la PQ e nient’altro, ma la ricetta era storicamente congelata sull’obiettivo *bilanciato* Dice + PQ. Ri-selezionare il punto del modello finale sulla PQ pura, con un secondo passaggio di soglie più fine

attorno all'ottimo grossolano (Figura 3), lo sposta da 0,4194 a **0,4264** (soglia 0,48, chiusura 1, dimensione minima 384, gate 0,97). La cross-selection – scegliere il punto su metà dei file di validazione e valutarlo sull'altra metà – quantifica il costo di overfitting della griglia fine in appena 0,0024, con le due metà che selezionano indipendentemente la stessa soglia e lo stesso gate: la rifinitura è reale, non rumore di griglia.




Figura 3: Dice e PQ di validazione al variare della soglia per il modello finale (senza post-processing). Le due metriche hanno massimi diversi; la ricetta spedita è selezionata sulla PQ, congiuntamente a chiusura, dimensione minima e gate.

5 Seconda campagna: le istanze

La prima campagna si è chiusa con una diagnosi – ciò che limita il punteggio è il riconoscimento delle istanze – e la seconda l’ha attaccata, con la stessa disciplina: un’ipotesi per run, i risultati falsificati riportati con la stessa cura di quelli confermati. Dall’Esperimento 7 in poi il test interno è incorporato nel training (+22% di dati), cosa legittima proprio perché non viene mai usato per scegliere alcunché.

Tabella 3: Seconda campagna, ogni run al proprio operating point, valutata con la metrica ufficiale a 2048² (non confrontabile con la Tabella 1, che è a soglia fissa senza post-processing).

Esp.	Cosa cambia	Dice	PQ	Verdetto
7	test interno nel training, ancora 1024	0,6544	0,3775	superato dall’8
8	1024 → 1536, TTA D4, gate di confidenza	0,6729	0,4194	modello finale
9	+ termine cIDice a 1536, warm start	0,6686	0,4064	falsificato
10	scale jitter ±25%	0,6670	0,4003	falsificato
11	cascata detect-then-refine	0,6560	0,3947	falsificato
12	target di consenso soft	0,6687	0,3863	falsificato
13	2048 nativo, finestre casuali da 1536	0,6692	0,4066	falsificato
14	Dice bilanciato per istanza, peso 0,35	0,6572	0,3611	falsificato
15	peso 20 sulla classe positiva (BCE)	0,6769	0,4198	falsificato per 0,007

5.1 Il tetto è il disaccordo tra annotatori, e vincola SQ

Fattorizzata, la $PQ = 0,4264$ del punto spedito è $SQ = 0,668 \times RQ = 0,638$ su 1144 istanze di ground truth (TP 712, FP 376, FN 432). In tredici esperimenti, con ogni capacità, risoluzione e architettura provata, SQ si è mossa dentro 0,66–0,68 e non oltre – contro un accordo tra coppie di annotatori umani di 0,59. La conclusione è scomoda ma utile: **SQ è una proprietà**

del processo di annotazione, non del modello. Ogni punto di PQ ancora sul tavolo passa da RQ: trovare più filamenti tra quelli marcati dagli annotatori, predirne meno tra quelli non marcati.

5.2 Dove sta davvero l'errore

All'operating point spedito, i 432 falsi negativi si dividono in 244 *pure miss* (nemmeno un pixel predetto sull'istanza), 159 *near miss* (un blob c'è ma resta a $\text{IoU} \leq 0,5$, rapporto d'area predetta/vera mediano 0,62 – il modello sotto-segmenta sistematicamente) e 29 *split*; i 376 falsi positivi in 128 *allucinazioni*, 239 su filamenti annotati ma non accoppiati e 9 *merge*. Il recall per istanza crolla con la dimensione, da 0,34 sotto i 500 pixel a 0,75 sopra i 5000 (Figura 4); al punto bilanciato, più orientato al recall, la fascia più piccola sale a 0,475 al costo di 62 falsi positivi in più, ed è lì che è stata letta la diagnosi dietro la prossima campagna. Dominano due famiglie – recall sulle istanze piccole e sotto-segmentazione; split e merge sono sotto il 4% del totale, ed è per questo che nessun meccanismo di split/merge è mai stato costruito.




Figura 4: Modello finale su tre osservazioni di validazione: ground truth dell'annotatore, mappa di probabilità predetta e istanze all'operating point spedito. Gli errori si concentrano sui filamenti piccoli e deboli.

Due avvertenze qualificano questi conteggi, ed entrambe sono state verificate. Primo: gli organizzatori hanno confermato nel forum della competizione che le annotazioni sono *incomplete* – filamenti visibili possono mancare – quindi parte delle 128 allucinazioni sono plausibilmente filamenti veri che nessun annotatore ha marcato; misurato sui file multi-annotatore, perfino i

blob con picco di probabilità sopra 0,85 sono marcati in media solo dal 63% degli annotatori, ed è per questo che all’ottimo di PQ sta il gate di confidenza, non una spinta al recall. Secondo: la commissione legge, accanto al punteggio, la distribuzione *many-to-one* / *one-to-many* (Figura 5): qui la struttura degli accoppiamenti è quasi uno-a-uno – su 1144 istanze annotate, 900 sono toccate da almeno una predizione e solo 67 da più di una; su 1088 predizioni, 960 toccano un filamento annotato e solo 20 più di uno.




Figura 5: Le distribuzioni riportate dal notebook di autovalutazione degli organizzatori, per il modello spedito sulla validazione: IoU e Dice su ogni coppia ground-truth/predizione sovrapposta, e le relazioni many-to-one / one-to-many (un hit è un qualunque overlap; il vincolo IoU > 0,5 della metrica è più severo).

5.3 Meccanismi misurati e scartati

Diversi meccanismi plausibili sono stati valutati e scartati – quasi tutti a basso costo, sulle mappe di probabilità *congelate* del modello finale, riprodotte bit-per-bit su una seconda macchina così che ogni idea di istanziazione si potesse misurare in minuti, senza addestrare.

Topologia e cascate. clDice a 1536, dove lo scheletro soft è finalmente significativo, perde comunque 0,013 PQ (Esp. 9); una cascata detect-then-refine perde 0,025 (Esp. 11). Entrambe attaccano la frammentazione, che l’analisi dell’errore aveva già mostrato marginale. I **target di consenso soft** (Esp. 12) trasformano il disaccordo tra annotatori nell’etichetta; la calibrazione quasi non si muove e la PQ scende di 0,033. Lo **scale jitter** (Esp. 10) costa 0,019. Le **soglie locali per componente** ($\tau_c = \alpha \cdot \text{picco}_c$, o un quantile della massa di probabilità della componente) dovrebbero correggere la sotto-segmentazione senza ingrassare le componenti già corrette; misurate, perdono contro la soglia globale, perché ogni componente sopravvissuta ha picco vicino a 1,0 e il taglio locale collassa in uno globale. La **dilatazione per componente** (trasformata di distanza verso la componente più vicina, quindi i merge sono impossibili) perde a ogni raggio – $\delta = 1$ px costa già 0,03 PQ – perché i near miss non sono copie erose del vero ma hanno forma diversa, tipicamente senza una coda debole. L’**ensemble di mappe di probabilità** perde due volte: con i fratelli deboli (Esp. 9, 10, 12), la cui calibrazione diversa diluisce le rilevazioni marginali, e perfino con l’Esp. 15, quasi pari e dal bias opposto – un guadagno aggregato di +0,003 che in cross-selection finisce *sotto* il modello singolo. La regola che emerge: su 169 voci di validazione, ogni guadagno sotto $\approx +0,005$ è indistinguibile dal rumore di selezione. E **Mask R-CNN** è stata scartata sulla carta: ricostruisce ogni maschera da una griglia 28×28 dentro un box allineato agli assi, un sovracampionamento di $\sim 25\times$ per asse per strutture la cui proprietà distintiva è essere larghe pochi pixel e lunghe centinaia.

Anche la **ricucitura post-hoc dei filamenti spezzati** è stata prima limitata e poi falsificata. Un oracolo che unisce, conoscendo la ground truth, esattamente i pezzi che trasformerebbero uno split in un match guadagna +0,017 PQ – ma solo 18 dei suoi 29 gruppi si convertono davvero, perché gli annotatori sono in disaccordo sulla connettività stessa. Nessun meccanismo cieco cattura quel tetto: ri-etichettare due istanze come una quando sono connesse a una soglia

di probabilità bassa (senza aggiungere pixel, quindi il Dice non si muove) guadagna +0,004 in aggregato, ma in cross-selection le due metà di validazione scelgono gli estremi opposti della griglia del parametro e il guadagno trasferito è $-0,006$ – rumore di selezione, non segnale; unire per vicinanza spaziale perde a ogni raggio utile. I ponti a bassa probabilità non distinguono un filamento spezzato da due filamenti vicini.

Che i meccanismi su estensione e ricucitura falliscano allo stesso modo è la scoperta della campagna: sotto-segmentazione e frammentazione vivono entrambe nel supporto di probabilità del modello, non nella sogliatura. Nessun post-processing può reclamarle; solo modifiche all'addestramento possono.

5.4 Validazione contro leaderboard

Il punteggio pubblico è sistematicamente sotto la validazione, e il divario si scompone in parti misurate: una submission iniziale prodotta da una ricetta non definitiva (vale $\sim 0,02$); la normale generalizzazione verso un diverso insieme di annotatori ($\sim 0,026$, misurata una volta sul test interno); e la composizione ($\leq 0,01$ – la PQ stratificata per numero di annotatori, stazione GONG e anno varia entro il rumore di conteggio, e il mix stazioni/anni del test rispecchia la validazione). Il percorso di submission è stato verificato pulito: componenti disgiunte per costruzione, convenzioni RLE allineate allo scorer degli organizzatori, zero componenti fuori dal disco solare.

6 Risultati, conclusioni e prossimi passi

Il modello consegnato è l'Esperimento 8 – ResNet18-U-Net a 1536^2 , test-time augmentation D4 – con l'operating point ri-selezionato sulla PQ pura: Dice di validazione 0,668, PQ **0,4264** ($t = 0,48$, chiusura 1, dimensione minima 384, gate di confidenza 0,97). La submission è pienamente riproducibile: il notebook di training rideriva esattamente questa ricetta dal checkpoint congelato, e il notebook di inferenza rigenera una `submission.csv` identica byte per byte.

Tre lezioni valgono oltre questo dataset. **Misurare ciò che il punteggio misura, dove lo misura:** selezionare l'operating point a risoluzione nativa, contro la definizione di PQ degli organizzatori e sull'obiettivo che la leaderboard riporta davvero è valso +0,020 Dice e +0,031 PQ complessivi – tutto gratis, senza riaddestrare. **Scegliere la metrica che vede il modo di fallire:** il Dice ha superato il tetto inter-annotatore all'Esperimento 2 ed è rimasto piatto; ogni miglioramento reale successivo era visibile solo nel termine di riconoscimento della PQ. Una valutazione limitata alla metrica del corso avrebbe dichiarato il progetto concluso dieci esperimenti prima. **Un'ipotesi falsificata non è un run sprecato:** dieci idee sono state misurate e respinte in questo studio, e ogni rigetto ha ridiretto lo sforzo – il fallimento dell'Esperimento 3 ha esposto il problema della risoluzione, e il fallimento di ogni meccanismo post-hoc sull'estensione (Sezione 5.3) è precisamente ciò che dimostra che l'errore residuo va attaccato in addestramento.

Uno dei seguiti preparati è già stato eseguito e falsificato: addestrare su finestre casuali 1536^2 del frame nativo 2048^2 (Esperimento 13) ha perso 0,020 PQ e spinto il recall sotto i 500 pixel giù a 0,31 – l'addestramento a finestre rinuncia al contesto dell'intero disco senza comprare i filamenti piccoli, e chiude la strada della risoluzione (+0,136, +0,009, $-0,020$ nei tre salti di scala). La loss bilanciata per istanza (Esperimento 14) è stata poi falsificata come termine *dominante*: con la Dice globale ridimensionata, il controllo dei falsi positivi è collassato e il recall delle istanze piccole è sceso a 0,09 – ma quello delle istanze da 2000–5000 pixel è salito a 0,76, quindi il termine merita un retest a peso ridotto, stesso arco degli Esperimenti 3 e 9. Il peso sulla classe positiva (Esperimento 15) ha poi prodotto il fallimento più istruttivo della campagna: la sotto-segmentazione è sparita (rapporto d'area dei near miss da 0,62 a 0,95), i pure miss sono

calati di un quinto e il Dice ha segnato il record del progetto (0,677) – ma le predizioni più grasse hanno gonfiato in parallelo i falsi positivi, chiudendo 0,007 sotto il campione. A chiudere la campagna è un fatto statistico: su 169 voci di validazione, ogni guadagno sotto $\approx +0,005$ è indistinguibile dal rumore di selezione. Il passo preparato che attacca esattamente questo è la *cross-validation a cinque fold*: ogni osservazione addestra un modello, e le predizioni out-of-fold sostengono una ricerca dell'operating point su $6,7\times$ più voci di annotazione – trasformando i guadagni che questa campagna poteva solo sospettare in guadagni che si possono misurare.