



Università degli Studi di Salerno

Corso di laurea magistrale in Ingegneria Informatica
Dipartimento di Ingegneria dell'Informazione ed Elettrica e Matematica
Applicata (DIEM)

Segmentazione di immagini di filamenti solari mediante architettura U-Net

Project work di Machine Learning

Gruppo

2026_MLrec_gr02

Componente

Francesco Peluso IE22700088

f.peluso29@studenti.unisa.it

Anno accademico 2025/2026

1 Introduzione

La segmentazione automatica dei filamenti solari richiede di individuare strutture sottili e poco contrastate all'interno di immagini dell'intero disco solare. Il problema è reso più difficile dal forte sbilanciamento tra foreground e sfondo, dalla variabilità nella forma e nella dimensione dei filamenti e dalla presenza di più annotazioni per la stessa osservazione. Una previsione utile deve quindi riconoscere i pixel appartenenti ai filamenti senza produrre un numero eccessivo di regioni spurie o frammentate.

Il lavoro ha l'obiettivo di costruire una pipeline riproducibile per la segmentazione delle immagini e la successiva estrazione delle singole istanze. Il modello di base è una U-Net con encoder ResNet18 pre-addestrato, scelta per combinare informazioni semantiche e dettaglio spaziale. Il Mean Dice costituisce la metrica principale, mentre la Panoptic Quality (PQ) viene usata per valutare anche il riconoscimento delle istanze. Sono inoltre misurati il consumo di memoria GPU e il tempo di esecuzione, poiché la soluzione deve poter essere addestrata e utilizzata con risorse limitate.

Durante lo sviluppo sono state eseguite **22 configurazioni sperimentali**. La relazione non riporta tutti i relativi log e risultati, ma approfondisce gli otto esperimenti numerati che hanno determinato le principali scelte progettuali. Sono inoltre confrontate le varianti U1 e U2 a piena risoluzione e i tre esperimenti con detector YOLO. In questo modo è possibile ricostruire il passaggio dalla baseline al modello consegnato, includendo anche le alternative che hanno migliorato la PQ a fronte di un costo computazionale maggiore.

Le sezioni successive definiscono le metriche e il protocollo di validazione, descrivono l'architettura e il training, quindi discutono gli esperimenti più significativi. La parte finale analizza gli errori, il costo computazionale e i limiti principali della soluzione.

2 Criteri di valutazione

2.1 Mean Dice

Per il record di validazione i , $\Omega_i = \{1, \dots, H_i\} \times \{1, \dots, W_i\}$ è l'insieme delle coordinate dei pixel di un'immagine alta H_i e larga W_i , cioè il suo dominio discreto. Siano $P_i \subseteq \Omega_i$ la maschera di foreground predetta e $G_i \subseteq \Omega_i$ l'unione delle istanze annotate. Il coefficiente Dice è definito come

$$D_i = \frac{2|P_i \cap G_i| + \varepsilon}{|P_i| + |G_i| + \varepsilon}, \quad (1)$$

dove ε evita una divisione per zero. Quando entrambe le maschere sono vuote, l'implementazione assegna $D_i = 1$. Sugli N record annotatore-immagine del validation set, la metrica riportata è

$$\text{Mean Dice} = \frac{1}{N} \sum_{i=1}^N D_i. \quad (2)$$

Questa misura sulla maschera unita è adatta al forte sbilanciamento tra le classi, perché non premia i pixel di sfondo classificati correttamente. Tuttavia, non descrive come il foreground sia diviso in oggetti distinti: un filamento frammentato in più componenti può comunque conservare una sovrapposizione elevata a livello di pixel.

2.2 Panoptic Quality

La PQ viene quindi impiegata come metrica complementare a livello di istanza. Per ogni record annotatore-immagine, le istanze predette e annotate vengono associate quando la loro Intersection over Union è maggiore di 0.5. Con questa soglia, le associazioni valide sono uno a uno. Le corrispondenze corrette e le istanze predette o annotate non associate vengono accumulate sull'intero

validation set come TP, FP e FN. La metrica è

$$PQ = \underbrace{\frac{\sum_{(p,g) \in TP} IoU(p,g)}{|TP|}}_{SQ} \times \underbrace{\frac{|TP|}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|}}_{RQ}. \quad (3)$$

La Segmentation Quality (SQ) misura la sovrapposizione media delle istanze associate, mentre la Recognition Quality (RQ) penalizza le istanze mancanti e quelle spurie. La distinzione è importante in questo studio, perché configurazioni con Mean Dice simile possono produrre numeri diversi di componenti frammentate o false positive.

Le due metriche vengono riportate per un operating point definito in modo esplicito. In particolare, il miglior Dice di una configurazione di output non viene mai combinato con la miglior PQ di un'altra.

3 Organizzazione dei dati e validazione

I dati annotati contengono 707 osservazioni diverse ma 1154 record di annotazione. Diverse osservazioni sono state annotate da due o tre esperti. Una suddivisione casuale dei singoli record avrebbe quindi potuto assegnare annotazioni della stessa immagine sia al training sia alla validazione. In tal caso, il modello sarebbe stato valutato su immagini già incontrate durante l'addestramento, con una conseguente sovrastima delle prestazioni. Per evitare questa forma di data leakage, ho effettuato lo split a livello di file, assegnando tutte le annotazioni della stessa osservazione a un unico insieme.

Lo split finale usa il seed 22 e contiene 601 file di training e 106 di validazione, corrispondenti a 985 e 169 record di annotazione. Il test set separato di Kaggle viene usato solo dal notebook di inferenza. Le appartenenze esatte sono salvate in `split_seed22.csv`, quindi il validation set riportato può essere ricostruito.

Le maschere contengono 8199 poligoni di filamenti e il foreground occupa solo circa lo 0.4% di un'immagine. L'area mediana di un'istanza alla risoluzione nativa è di circa 1230 pixel. Nelle osservazioni con più annotazioni, il Dice medio tra coppie di annotatori è circa 0.62. Questo valore non definisce un limite superiore umano, ma mostra che alcuni errori apparenti della previsione possono dipendere anche dalle differenze tra gli annotatori.

La validazione è stata usata per scegliere il checkpoint, confrontare gli esperimenti e selezionare le impostazioni finali dell'output. Il riuso dello stesso split può rendere ottimistico il punteggio finale; per questo considero con cautela le differenze piccole.

4 Architettura, preprocessing e training

4.1 Architettura della rete

La rete implementata segue la struttura encoder-decoder della U-Net. Il percorso contrattivo estrae caratteristiche progressivamente più astratte riducendone la risoluzione spaziale; il percorso espansivo ripristina la risoluzione originale. Le skip connection concatenano le feature dell'encoder con quelle del decoder alle scale corrispondenti, permettendo di recuperare informazioni di localizzazione che andrebbero altrimenti perse durante il downsampling.




Figura 1: Esempi usati per controllare il contrasto delle immagini e la variabilità delle annotazioni.





Figura 2: Schemi di riferimento delle due componenti combinate nel modello implementato.

Una ResNet18 pre-addestrata su ImageNet sostituisce l'encoder originale della U-Net. I blocchi residui apprendono una trasformazione $F(x)$ e sommano la connessione identità, producendo $F(x) + x$; questa struttura facilita la propagazione del gradiente nell'estrattore di feature. Vengono mantenuti soltanto lo stem convoluzionale e i quattro stadi residui. Il flattening e le teste di classificazione mostrate nella Figura 2(b) sono rimossi, mentre le feature con 64, 128, 256 e 512 canali vengono fornite al decoder della U-Net.

Gli schemi riportati sono generali. Nella rete implementata, la prima convoluzione di ResNet18 è adattata da tre canali RGB a un singolo canale in scala di grigi combinando i pesi pre-addestrati. Il decoder termina con una convoluzione 1×1 che restituisce un logit di foreground per pixel. La rete completa contiene 14.34 milioni di parametri addestrabili.

4.2 Pipeline di input e inferenza

L'esperimento selezionato conserva il campionamento nativo a 2048^2 . Durante il training viene estratto un crop casuale a 1536^2 da ogni frame. Durante l'inferenza, quattro tile sovrapposti a 1536^2 coprono l'intera immagine; le rispettive mappe di probabilità vengono fuse prima del thresholding. La procedura mantiene il dettaglio dei pixel nativi limitando la memoria richiesta da ogni passaggio forward.



Immagini e maschere vengono decodificate una sola volta in file uint8 mappati in memoria. La cache evita di ripetere a ogni epoca la decodifica JPEG e la rasterizzazione dei poligoni senza conservare l'intero dataset in RAM. Contiene soltanto campioni non modificati; l'augmentation viene generata in modo indipendente a ogni epoca. Durante il training applico un crop casuale 1536^2 , riflessioni orizzontali e verticali (con probabilità 0.5), una rotazione casuale di 0, 90, 180 o 270 gradi e variazioni fotometriche. In particolare, luminosità e contrasto variano entro il $\pm 20\%$ e nel 30% dei casi viene aggiunto rumore gaussiano. Le trasformazioni geometriche sono applicate contemporaneamente all'immagine e alla maschera.

4.3 Ottimizzazione

Per un singolo campione, sia z_j il logit nel pixel j , $p_j = \sigma(z_j)$ la relativa probabilità di foreground e $y_j \in \{0, 1\}$ il target, considerando M pixel. I termini della loss sono i seguenti:

- **Binary Cross-Entropy (BCE)**: valuta la differenza tra la probabilità prevista e il target per ogni pixel. Fornisce quindi una supervisione locale, pixel per pixel.

- **Soft Dice loss:** misura la sovrapposizione tra la maschera prevista e quella reale. Risulta utile in presenza di forte sbilanciamento tra foreground e sfondo, perché considera direttamente l'area delle due regioni.
- **Loss complessiva:** è la media dei due termini, con peso 0.5 per ciascuno.

Le definizioni utilizzate sono

$$\begin{aligned}\mathcal{L}_{\text{BCE}} &= -\frac{1}{M} \sum_{j=1}^M [y_j \log(p_j) + (1 - y_j) \log(1 - p_j)], \\ \mathcal{L}_{\text{Dice}} &= 1 - \frac{2 \sum_{j=1}^M p_j y_j + \varepsilon}{\sum_{j=1}^M p_j + \sum_{j=1}^M y_j + \varepsilon}, \quad \varepsilon = 10^{-6}, \\ \mathcal{L} &= 0.5 \mathcal{L}_{\text{BCE}} + 0.5 \mathcal{L}_{\text{Dice}}.\end{aligned}\tag{4}$$

La costante di stabilizzazione ε evita un denominatore nullo; entrambi i termini vengono mediati sul mini-batch. Nell'esperimento 13 non viene usato un peso per la classe positiva. AdamW è configurato con learning rate 10^{-4} , weight decay 10^{-4} e cosine decay per un massimo di 20 epoche. La selezione del checkpoint e l'early stopping si basano sul Dice di validazione; il checkpoint salvato corrisponde all'epoca 12.

Il batch size effettivo è 2. Viene elaborato un crop alla volta e i gradienti sono accumulati su due passaggi forward/backward. Sono inoltre attivi gradient checkpointing e mixed precision in bfloat16. Il training si è interrotto dopo 15 epoche e ha richiesto un picco di 3.04 GB; l'inferenza ha richiesto 2.53 GB.

Infine, la mappa di probabilità viene convertita in componenti connesse usando l'operating point selezionato sulla validazione. I valori finali e la distinzione tra configurazioni orientate al Dice e alla PQ sono riportati nella Sezione 6.

5 Strategia sperimentale

5.1 Ipotesi e criteri decisionali

Il piano sperimentale è stato definito intorno a un numero limitato di ipotesi. A ogni ipotesi è stato associato un confronto misurabile e una decisione ricavabile dal risultato. La Tabella 1 riassume questa struttura.

Durante lo studio sono state eseguite 22 configurazioni. La relazione ne riporta solo gli otto esperimenti numerati che hanno fornito evidenze per le ipotesi precedenti; le U-Net a piena risoluzione e gli esperimenti con detector YOLO sono confrontati separatamente nella Sezione 7.2.

Nel primo esperimento con transfer learning è stato modificato anche il learning rate, mentre le risoluzioni più elevate richiedono impostazioni di memoria diverse. I risultati consentono quindi di prendere decisioni progettuali, ma non sempre permettono di attribuire l'intera differenza di punteggio a una singola variabile.

Tutti i punteggi finali sono ricalcolati alla risoluzione nativa e i parametri di output sono scelti esclusivamente sui dati di validazione.

In alcuni esperimenti il seed di training è stato cambiato un paio di volte, mantenendo invariato lo split. I risultati ottenuti sono rimasti pressoché invariati, suggerendo una variabilità limitata per le configurazioni considerate.

5.2 Alternative non mantenute

Le principali alternative considerate e poi scartate sono:

- **Loss alternative:** le varianti topologiche, soft e bilanciate per istanza non hanno dato un guadagno stabile.

Tabella 1: Ipotesi usate per guidare il lavoro sperimentale.

Ipotesi	Verifica	Criterio decisionale
Le feature pre-addestrate sono utili sul dataset annotato, di dimensioni limitate.	Confrontare una U-Net addestrata da zero con un encoder ResNet18.	Mantenere il transfer learning solo in presenza di un Dice migliore.
La frammentazione dipende soprattutto dalla funzione di loss.	Introdurre Tversky e cIDice mantenendo la bassa risoluzione.	Conservare la loss specializzata solo se migliorano Dice e PQ.
I filamenti sottili vengono persi durante il downsampling.	Aumentare l'input da 512 a 1024 e poi a 1536 pixel.	Preferire la scala che migliora il riconoscimento a un costo accettabile.
Il contesto del disco e il dettaglio nativo producono errori diversi.	Confrontare immagini intere ridimensionate e crop a risoluzione nativa.	Valutare insieme Dice, PQ e categorie di errore sulle istanze.
Il training ad alta risoluzione può rispettare i limiti di memoria.	Sostituire il batch fisico di 2 con due micro-batch accumulati.	Accettare la modifica se la qualità resta simile e la memoria diminuisce.

- **Scale jitter:** vantaggi ridotti e non costanti tra le prove.
- **Post-processing:** la cascata detect-then-refine e l'unione delle componenti hanno aumentato complessità o rischio di fusione.
- **Encoder ResNet34:** memoria aggiuntiva senza aumento del Mean Dice.
- **Detector:** PQ più alta, ma Mean Dice inferiore e costo maggiore.

Questi risultati hanno orientato la scelta della scala dell'input e dell'architettura finale.

6 Evidenze sperimentali e scelta del modello

La Tabella 2 riporta le otto configurazioni numerate che hanno modificato più direttamente una scelta progettuale. I valori contrassegnati da un asterisco appartengono al protocollo iniziale, in cui la probabilità di foreground viene convertita in maschera usando la soglia 0.5; i rimanenti sono stati ricalcolati alla risoluzione nativa secondo l'obiettivo di validazione indicato.

Tabella 2: Esperimenti numerati mantenuti nel percorso decisionale.

Esp.	Confronto principale	Dice	PQ	Evidenza ottenuta
1	U-Net da zero, 512 ²	0.6415*	–	baseline di riferimento
2	encoder ResNet18 pre-addestrato	0.6552*	0.2505*	transfer utile
3	Tversky + cIDice, 512 ²	0.4937*	0.0618*	ipotesi sulla loss respinta
5	risoluzione 512 → 1024	0.6665	0.4022	importanza della scala
8	immagine intera a 1536 ²	0.6678	0.4264	buona PQ del singolo modello
13	immagine nativa, crop 1536 ²	0.6762	0.3591	Mean Dice più alto
15	1536 ² , BCE pesata, batch 2	0.6769	0.4198	qualità, ma 5.20 GB
15m	exp. 15 con controllo memoria	0.6650	0.4153	alternativa entro i limiti

6.1 Dalla baseline alla risoluzione spaziale

I passaggi principali sono riassunti di seguito:

- **Esperimenti 1–2:** l'encoder ResNet18 pre-addestrato ha fornito un punto di partenza migliore dell'inizializzazione casuale.

- **Esperimento 3:** Tversky+clDice ha ridotto entrambe le metriche a 512^2 ; la frammentazione è stata quindi ricondotta soprattutto alla scala spaziale.
- **Esperimenti 5 e 8:** aumentare l'input a 1024^2 e 1536^2 ha migliorato la PQ più delle loss specializzate, motivando il ritorno a BCE+Dice.

6.2 Candidati finali

L'esperimento 13 ha eliminato il ridimensionamento dell'intero frame e ha usato crop a 1536^2 estratti dalle immagini native a 2048^2 . Ha ottenuto il Mean Dice più alto, pari a 0.6762, mantenendosi sotto i limiti facoltativi di memoria. Costituisce quindi il modello selezionato per la consegna.

Gli esperimenti 15 e 15m rispondono a una domanda diversa. La BCE pesata applicata all'intero frame ridimensionato ha ridotto le istanze spurie e aumentato la PQ. L'esperimento 15 ha richiesto 5.20 GB durante il training; 15m ha riprodotto l'approccio con gradient accumulation, checkpointing e mixed precision, riducendo il picco a 2.63 GB. Rispetto all'esperimento 13, 15m guadagna 0.0562 di PQ ma perde 0.0112 di Mean Dice. Poiché il Mean Dice è la metrica principale del project work, 15m viene documentato come secondo candidato finale ma non è usato come modello consegnato. La sua submission orientata alla PQ ha ottenuto 0.35 sulla leaderboard pubblica di Kaggle.




Figura 3: Andamento del training dell'esperimento 13. Il checkpoint selezionato sul Mean Dice corrisponde all'epoca 12; l'operating point finale viene scelto successivamente sulle probabilità di validazione.

6.3 Selezione dell'operating point

La rete dell'esperimento 13 restituisce una probabilità per pixel. Soglia, chiusura morfologica, dimensione minima delle componenti e filtro di confidenza sono stati cercati congiuntamente alla risoluzione nativa. La procedura orientata al Dice è riportata nella Tabella 3.

Tabella 3: Procedura di inferenza del modello consegnato.

Impostazione	Valore selezionato
checkpoint	esperimento 13, epoca 12
soglia di probabilità	0.30
iterazioni di closing	0
dimensione minima	128 pixel a 2048^2
filtro di confidenza	disabilitato
Mean Dice di validazione	0.6762
PQ allo stesso operating point	0.3591




Figura 4: Mean Dice e PQ di validazione favoriscono impostazioni di output diverse per l’esperimento 13.

Il grafico mostra perché è necessario dichiarare l’obiettivo di selezione. Una maggiore selettività sulle componenti può aumentare la PQ riducendo però la sovrapposizione della maschera unita. I valori di Dice e PQ riportati fanno quindi sempre riferimento alla stessa configurazione congelata.

7 Analisi degli errori e modelli aggiuntivi

7.1 Errori del modello consegnato

All’operating point selezionato, l’esperimento 13 produce sulla validazione 733 istanze associate, 845 falsi positivi e 411 falsi negativi. La SQ è 0.667 e la RQ è 0.539. La differenza indica che gli errori di riconoscimento hanno un effetto sulla PQ maggiore rispetto ai bordi degli oggetti già associati.

Il recall dipende fortemente dalla dimensione delle istanze: è pari a 0.44 sotto i 500 pixel, 0.65 tra 500 e 1000 e circa 0.69–0.72 nei gruppi più grandi. I filamenti piccoli o deboli costituiscono quindi il limite più evidente del modello consegnato.

Tabella 4: Categorie di errore dell’esperimento 13 sulla validazione.

	Categoria	Numero	Significato
FN (411)	mancato completo	113	nessuna sovrapposizione predetta
	quasi corretto	245	esiste overlap, ma $\text{IoU} \leq 0.5$
	divisione	53	un’annotazione coperta da più parti
FP (845)	FP senza overlap	418	non tocca alcun pixel annotato
	non associato	411	esiste overlap, ma $\text{IoU} \leq 0.5$
	fusione	16	una previsione copre più annotazioni

Le distribuzioni nella Figura 6 forniscono un’ulteriore lettura dello stesso risultato. Tra le coppie ground-truth/predizione sovrapposte, la IoU media è 0.516 e il Dice medio è 0.648. Questi valori sulle coppie non sostituiscono le metriche globali, perché escludono le componenti prive di associazione.

7.2 Modelli più pesanti e secondo candidato finale

Per completezza, la Tabella 5 riporta le configurazioni che hanno esplorato una capacità maggiore oppure un diverso equilibrio tra Mean Dice e PQ. I valori di memoria sono picchi misurati, non stime ricavate dal numero di parametri.




Figura 5: Esempi di validazione dell'esperimento 13: annotazione, mappa di probabilità e componenti connesse finali. Una risposta esterna a una singola annotazione può essere un falso positivo oppure riflettere un disaccordo tra annotatori.




Figura 6: Sovrapposizioni tra coppie e gradi di associazione dell'esperimento 13 sulla validazione.

Tabella 5: Candidato finale e configurazioni con costo maggiore. Il trattino indica che non è disponibile o applicabile un picco separato di training o inferenza.

ID	Configurazione	Dice	PQ	Train GB	Test GB
13	U-Net ResNet18, crop nativi	0.6762	0.3591	3.04	2.53
15m	U-Net ResNet18, frame 1536 ²	0.6650	0.4153	2.63	2.53
U1	U-Net ResNet18, frame 2048 ²	0.6691	0.4211	9.20	4.32
U2	U-Net ResNet34, frame 2048 ²	0.6670	0.4282	9.23	4.36
Y1	YOLOv8m-seg, 1792 ² (40 ep.)	0.6150	0.4170	21.59	—
Y2	YOLOv8m-seg, 1792 ² (39 ep.)	0.6181	0.4197	21.59	—
Y3	YOLOv8x-seg, 1792 ² (100 ep.)	0.6324	0.4263	38.74	—

U1 e U2 elaborano l'intero frame alla risoluzione nativa. U2 sostituisce ResNet18 con ResNet34, aumentando i parametri addestrabili da 14.34 a 24.45 milioni. La PQ migliora, ma i picchi di training superano 9 GB e il Mean Dice resta inferiore a quello dell'esperimento 13.

Gli esperimenti YOLO (Y1–Y3) hanno fornito una PQ discreta, ma un Mean Dice inferiore all'esperimento 13. Il modello più grande, Y3, raggiunge 0.4263 di PQ ma richiede 38.74 GB di memoria in training; per questo il ramo basato su detector non è stato scelto.

L'esperimento 13 richiede circa 107 secondi per epoca e ha completato 15 epoche in 26.7 minuti. L'inferenza su 180 immagini di test ha richiesto circa 15.3 minuti. I picchi misurati in training e inferenza rimangono sotto i limiti facoltativi di 5 GB e 4 GB.

8 Conclusioni

Gli esperimenti mostrano che il transfer learning con ResNet18 e la conservazione del dettaglio spaziale sono più utili delle loss specializzate provate. Mean Dice e PQ misurano aspetti diversi: una previsione più selettiva può riconoscere meglio le istanze, ma ridurre la sovrapposizione della maschera complessiva.

L'esperimento 13 è il modello consegnato: una U-Net ResNet18 addestrata su crop casuali a 1536^2 da frame nativi a 2048^2 . Ottiene **0.6762 di Mean Dice** e **0.3591 di PQ**; il picco GPU è 3.04 GB in training e 2.53 GB in inferenza.

La configurazione 15m raggiunge 0.6650 di Mean Dice e 0.4153 di PQ entro i limiti di memoria, mentre i modelli più pesanti aumentano la PQ ma non il Mean Dice e richiedono molte più risorse.

Il limite principale è il possibile ottimismo dovuto al riuso della validation per il confronto e la selezione dell'output; in alcune prove il cambio del seed ha comunque prodotto risultati pressoché invariati. Un possibile sviluppo è migliorare il recall dei filamenti più piccoli senza aumentare i falsi positivi.